Clasificación de especies de Frailejón en el sector del páramo del Sumapaz mediante la morfología foliar

Juan David Leal Campuzano
Universidad Nacional de Colombia

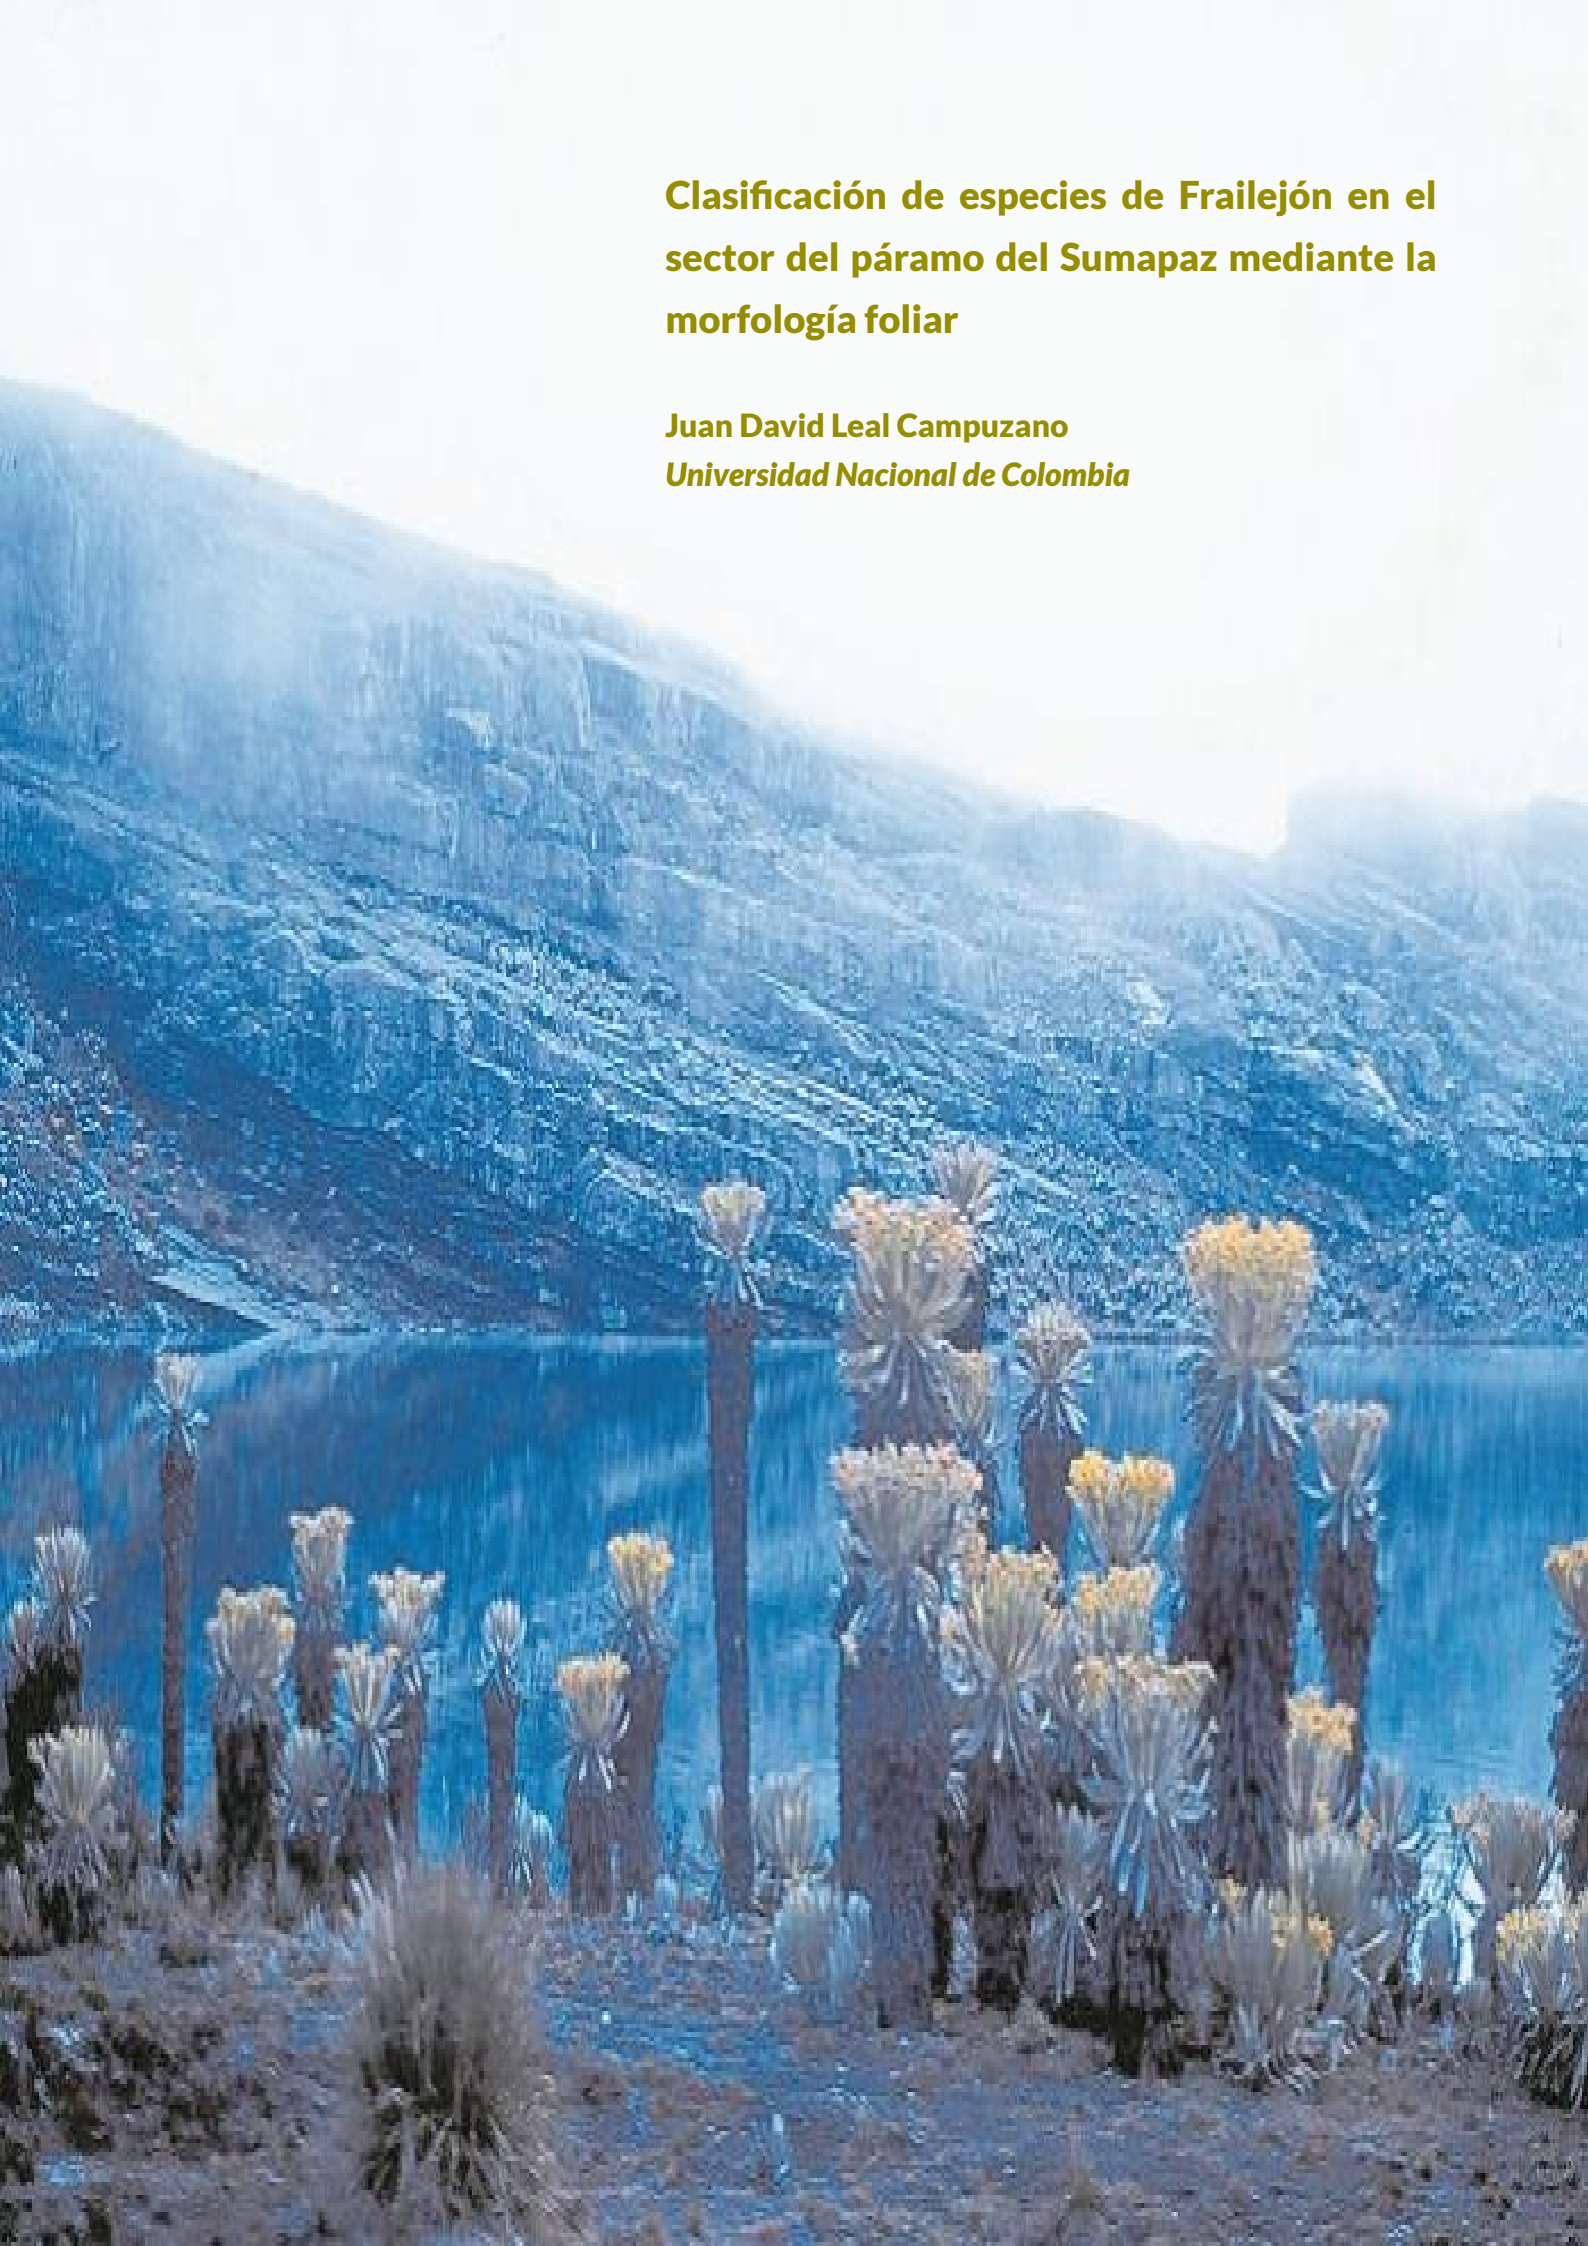

1 INTRODUCCIÓN

Las especies a menudo se consideran unidades básicas de diversidad biológica en ecología, evolución, biogeografía y biología de la conservación [3]; la intervención de la mano del hombre y el cambio climático global está afectando el ecosistema de los páramos en Colombia y en general del territorio suramericano, esto está generando que un género de plantas que tiene gran predominio en estos terrenos y que además sirven como medio de tratamiento del agua y retención de minerales en el suelo, presenten cambios debido a una alteración de su ecosistema.

Existe una necesidad en distinguir el ecosistema en donde se trabaja, esto genera la necesidad de identificar las diferentes especies que componen el mismo, en el presente proyecto y dado el predominio del frailejón en los páramos, se creará un algoritmo que permita clasificar tres distintas especies de frailejón endémicas del páramo del Sumapaz a través de las morfología de sus hojas: E. Grandinflora, E. Aregentea y E. Summapacis, especies predominantes en este lugar.

En un proceso de estos de clasificación, hay una alta demanda de tiempo y costos, la aplicación de este algoritmo permitirá a los especialistas contar con ayuda al momento de clasificar entre especies de frailejón y tener una mayor certeza, por otro lado, en la literatura no existe un algortimo que se especialice en plantas de esta especie, por ende será algo nuevo y de gran ayuda para los investigadores; el desempeño a medir en este algoritmo y lo que concierne a los investigadores tiene que ver con la precisión del modelo, es la finalidad del proyecto a nivel cuantitativo.

Los datos en bruto consisten en 180 fotografías tomadas en el páramo del Sumapaz a las cuales se les debió realizar un preprocesamiento específico y además se debieron obtener ciertos tipos de características de las imágenes preprocesadas para poder entrenar cada uno de los tres modelos [4], [2].

Los resultados que se obtuvieron parten de 3 diferentes algoritmos que presentaron una precisión que osciló entre el 76% y el 88% al momento de clasificar cada especie, los tres arrojaron una precisión prometedora teniendo en cuenta la calidad de los datos y el parecido existente entre la especie Grandinflora y la especie Summapacis lo cual dificultó la identificación entre ellas, los algoritmos tuvieron buena presición al identificar la especie Argentea que se diferenciaba bastante bien de las otras especies por su forma, uno de los modelos, el mejor, obtuvo un desempeño del 87%, desempeño prometedor para el problema planteado al inicio.

El proyecto tuvo buenos resultados a pesar de las complicaciones iniciales con las fotografías, se espera que el algoritmo pueda ser generalizado a otras especies dado que parte del algortimo es la extracción de caracteríticas, algo que no depende enteramente de los datos iniciales que son las hojitas preprocesadas, esto quiere decir que dado el caso en que se obtengan nuevas fotografías de otras especies, quizás el modelo permita de igual manera distinguirlas y clasificarlas, lo único faltante sería tener esas nuevas hojas previamente clasificadas por el experto para así poder entrenar de nuevo el modelo.

2 DATOS, MÉTODOS Y RESULTADOS

2.1 DATOS

Para tal estudio, se han obtenido un conjunto de 180 fotografías tomadas en el páramo del Sumapaz [4] en las que se pudieron encontrar alrededor de 4 o 5 hojitas por fotografía, para el preporcesamiento de estas fotografías de decidió eliminar el fondo y separar la hojas en imágenes por unidad, este trabajo tuvo un alto grado de complejidad ya que las fotografías orignilaes no tuvieron unos estándares al ser tomadas, por ende, tamaños y colores se perdieron o se trasnformaron en el preprocesamiento de las fotografías origninales.

Después del preprocesamiento se continuó con la extracción de características de las imágenes; al ser figuras cerradas se pensó en hallar características representativas de una figura cerrada, se tomó como base la elipse y a partir de esta figura se obtuvieron las siguientes características básicas: área, perímetro, longitud del eje mayor y del eje menor y la medida del eje focal segun [2], [6]. Como primera medida se pensó en usar estas características pero, como las imágenes perdieron proporción, tamaño y color en el preprocesamiento entonces se decidió crear nuevas características a partir de las básicas halladas, estas características se muestran en el apéndice en el anexo 1.

Como se puede observar, todas las características son razones y por ende pierden la desventaja del tamaño y la proporción y además como un plus son valores pequeños, esto permite al algortimo tener un control sobre los cálculos, condiciones necesarios en los modelos según [7] y [5].

2.2 MÉTODOS

Después de la obtención de las características mencionadas anteriormente, se realizó un análisis de los datos a través de la creación de diferentes espacios de características, se obtiene la matriz de correlación entre los datos y se representan dos a dos observando una separación evidente entre cada especie con algún error e identificando una correlación alta entre agunas características.

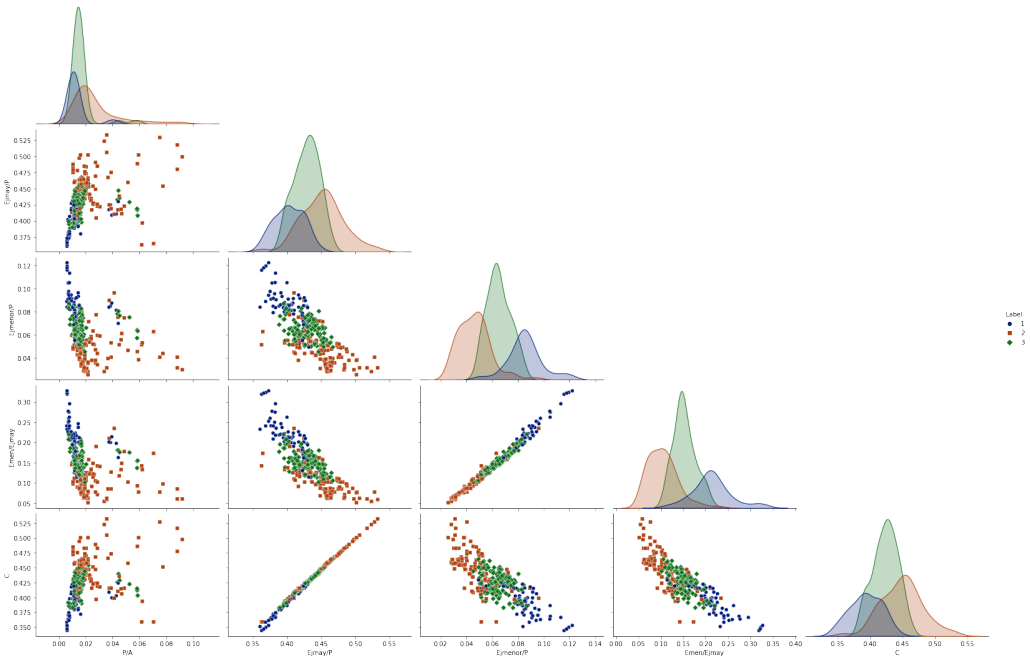

FIGURE 1: REPRESENTACIÓN DE LAS TRANSFORMACIONES DE LAS CARACTERÍSTICAS BÁSICAS EN DOS DIMENSIONES. *(GRÁFICA HECHA EN PYTHON, SNS)*

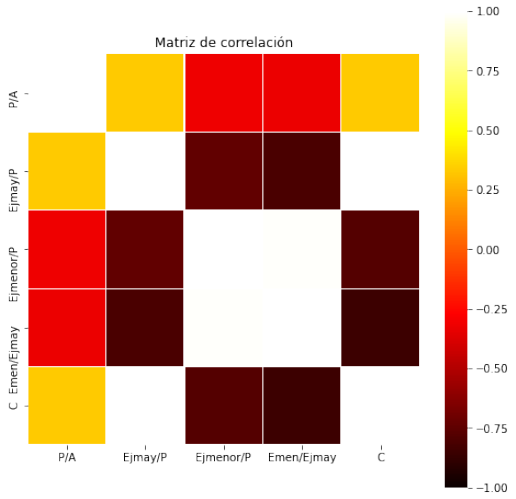

FIGURE 2: *MATRIZ DE CORRELACIÓN PARA LOS DATOS BÁSICOS*

En la mayoría de gráficas de la Figura 1 se logra observar una buena separación sin embargo en la figura 2 se ve una alta correlación entre algunas variables.

Se decide crear a partir de las 5 características obtenidas grupos de parejas, triplas, cuartetos y por último las 5 componentes, esto a razón de que si se aplica el algortimo teniendo una dimesionalidad relativamente alta, por la poca cantidad de datos, quizás el algortimo no clasifique bien, además se esperaba que usando grupos de características con una baja dimesionalidad se pudiera separar el espacio y hacer más óptimos los modelos.

Para tener una mejor observación de baja dimensionalidad se aplicaron los algortimos de PCA y TSNE para visualuzar los datos del espacio completo, se observó un buena separación usando PCA, algo que no se obtuvo con TSNE.

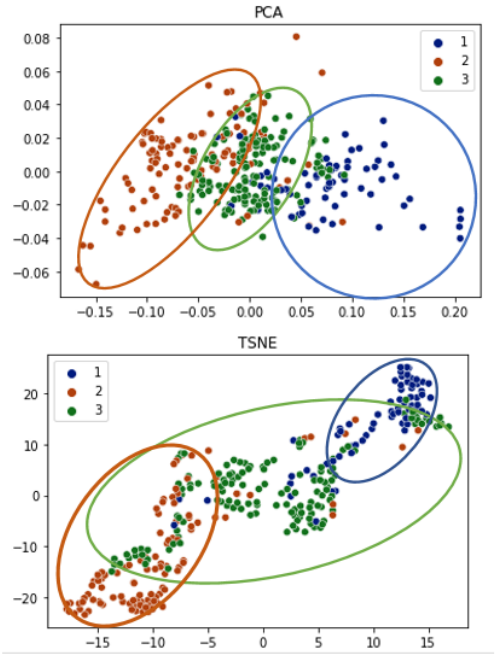

FIGURE 3: *PCA Y TSNE SEPARADOS POR GRUPOS DE ESPECIE EN LAS CARACTERÍSTICAS BÁSICAS*

Los algortimos usados para la clasificación fueron: RFC(RandomforestClassifier), ETC(ExtraTreesClassifiers), KNC(KNeighborsClassifier), modelos escogidos por tener una alto éxito en la clasificación multiclase como se

menciona en [1], [7], [5], además se hizo una busqueda hiperparámetros en cada algoritmo, se muestran en el Apéndice en el anexo 2.

2.3 RESULTADOS

En la aplicación de los tres modelos al conjunto de caraterísticas completo se obtuvieron las siguientes matrices de confusión:

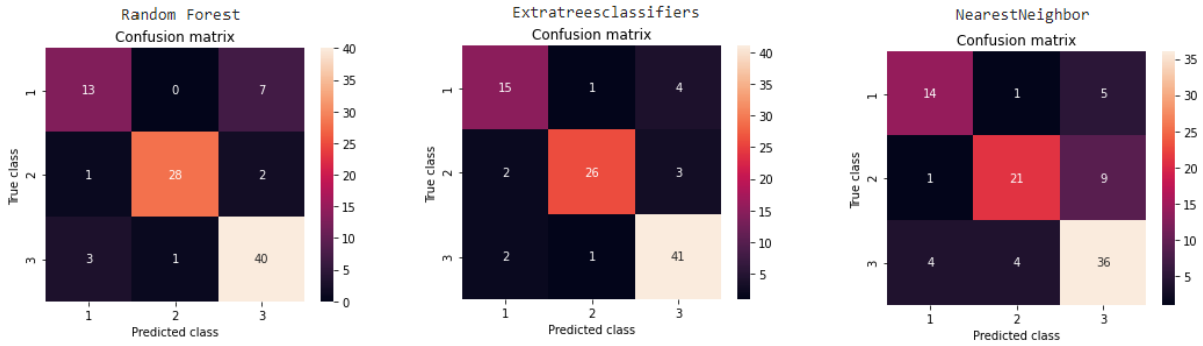

FIGURE 4: *MATRIZ DE CONFUSIÓN PARA CADA MODELO ENTRENADO CON EL ESPACIO 1 COMPLETO*

Se puede observar que existe una confusión de los modelos entre la especie 1 y la especie 3 (E. Grandinflora y E. Summpacis), la especie 2 (E. Argentea) tiene mejores resultados en los dos primeros clasificador a pesar de confundirse un poco con la espcie 3 en el tercer modelo, también se puede observar el desbalance de los datos y a pesar de eso tener resultados bastante buenos.

Al entrenar cada modelo con cada subgrupo hecho del espacio completo se obtuvieron las siguientes gráficas que muestran los resultados obtenidos.

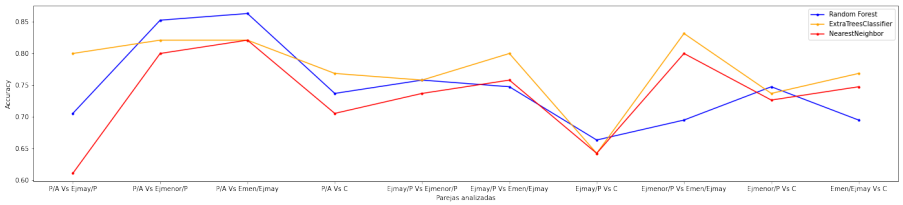

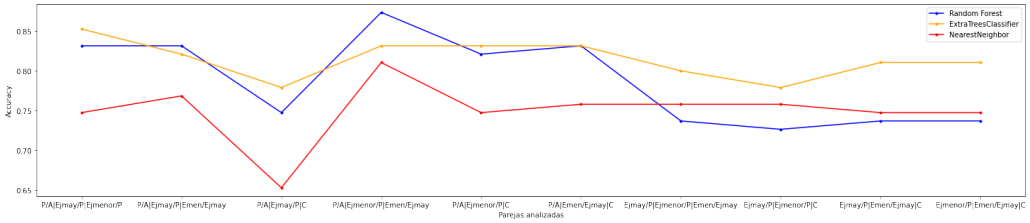

En la tabla 1 se muestran los mejores desempeños con los mejores grupos respecto a cada modelo y sus respectivos parámetros.

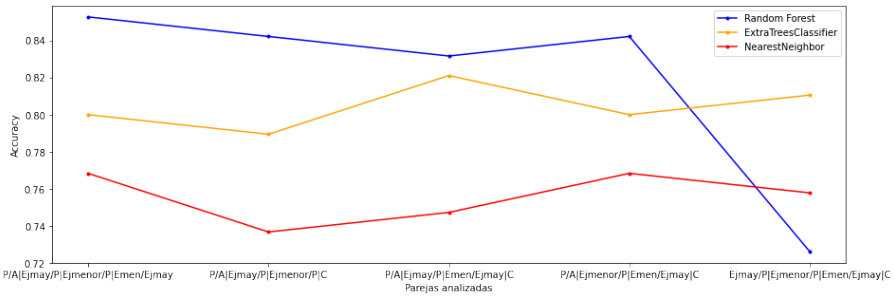

FIGURE 5: ANÁLISIS POR SUBGRUPOS, ARRIBA POR PAREJAS, EN EL MEDIO POR TRIPLETAS Y ABAJO POR CUARTETOS

Grupo	Modelo	Desmpeño	Parámetros	Subgrupo
Parejas	RFC	0.8631	min_samples_leaf: 10, n_estimators: 50	P/A Vs Emen/Ejmay
	ETC	0.831	min_samples_leaf: 10, n_estimators: 10	Ejmen/P Vs Emen/Ejmay
	KNC	0.82	leaf_size: 15, n_neighbors: 20	P/A Vs Emen/Ejmay
Triplas	RFC	0.873	min_samples_leaf: 5, n_estimators: 10	P/A,Ejmnr/P,Emen/Ejmy
	ETC	0.852	min_samples_leaf: 5, n_estimators: 10	P/A, Ejmy/P, Ejmnr/P
	KNC	0.81	leaf_size: 15, n_neighbors: 5	P/A, Ejmnr/P, Emen/Ejmy
Cuartetos	RFC	0.852	min_samples_leaf: 5, n_estimators: 10	P/A, Ejmay/P, Ejmnr/P, Emen/Ejmy
	ETC	0.8	min_samples_leaf: 5, n_estimators: 10	P/A, Ejmy/P, Emen/Ejmay, C
	KNC	0.768	leaf_size: 15, n_neighbors: 5	P/A, Ejmay/P, Ejmenor/P, Emen/Ejmy

TABLE 1: RESULTADOS DE LOS SUBGRUPOS DEL ESPACIO FORMADO A PARTIR DE LAS CARACTERÍSTICAS BÁSICAS.

3 CONCLUSIONES

El objetivo principal de este proyecto se difinió en crear un algortimo que logre brindar una ayuda al especialista a identificar entre tres especies de Espeletia: E. Grandinflora, E. Argentea y E. Summapacis y ahorre tiempo, materiales y costos al momento de ser realizada esta clasificación por un especialista.

Se planteó tener un desempeño de al menos 80%, los modelos de RFC(RandomForestClassifiers), ETC(ExtraTreesClassifiers) y KNC(KNeighborsClassifier) han logrado el propósito creado, a pesar de que no se obtuvo una precisión de más del 90% el clasificador RFC(RandomForestClassifiers) obtuvo un desempeño de 87.3% algo por encima de lo estimado, haciendo una observación sobre la calidad de las imágenes se logró una buena precisión con diferentes combinaciones de cada grupo.

Como se mencionó anteriormente, los algoritmos tiene en cuenta la extracción de características de las imágenes preprocesadas, esto quiere decir que es posible generar un modelo con especies diferentes de Espeletia y quizás se logre obtener de la misma manera tan buen desempeño como el obtenido en este documento, ese será un siguiente objetivo a trabajar.

Se trabajará en aumentar el desempeño mediante la busqueda de otras caracteríticas que permitan identificar con un mayor desempeño cada especie, sobretodo las especies en las que el modelo presenta confusión.

4 APÉNDICE

ANEXO 1: CARACTERÍSTICAS OBTENIDAS A PARTIR DE LAS BÁSICAS

$$P/A = \frac{Perimetro}{Area}$$
$$Ejmenor/Ejmay = \frac{Eje_{menor}}{Eje_{mayor}}$$
$$Ejmay/P = \frac{Eje_{mayor}}{Perimetro}$$
$$Ejmenor/P = \frac{Eje_{menor}}{Perimetro}$$
$$C = \frac{\sqrt{Eje^2_{mayor} - Eje^2_{menor}}}{Perimetro}$$

ANEXO 2: HIPERPARÁMETROS PARA CADA ALGORITMO

- RandomForestClassifier y ExtratreesClasiffier:
  n_estimators: [5, 10, 20, 50, 100]
  min_samples_leaf: [5, 10, 50]
- Knearestneighbor:
  n_neighbors: [3, 5, 10, 20],
  leaf_size: [15, 30, 45]

Código del proyecto en Github

References

[1] Bobadilla J. *Machine Learning y Deep Learning: Usando Python, Scikit y Keras*, Ra-ma, 2020.

[2] Burger W., Burger M. *Principles of digital image processing*, Springer 2009.

[3] M. F. Cárdenas Agudelo *Ecohydrology of páramos in Colombia: Vulnerability to climate change and land use*, Universidad Nacional de Colombia 2016.

[4] Pineda Yam, Cortés Andrés, Madriñán Santiago, Jiménez Iván *The Nature of Espeletia Species*, 2020.

[5] Prinzie A., Van den Poel D. *Random Forests for multiclass classification: Random MultiNomial Logit*, Department of Marketing at Ghent University, Ghent, Belgium,2008.

[6] Wäldchen J, Mäder P *Plant Species Identifcation Using Computer Vision Techniques: A Systematic Literature Review*, Springer, 2017.

[7] Shichao Zhang,Debo Cheng, Ming Zong,Lianli Gao *Self-representation nearest neighbor search for classification*, University of Electronic Science and Technology of China, Chengdu, China, 2016.